



Klasifikasi Citra X-Ray Penyakit Pneumonia dengan Menggunakan Model CNN

¹Akmal Muhammad Naim, ²Qhistina Dyah Khatulistiwa, ³Agus Eko Minarno

^{1,2,3,4}Informatika, Teknik, Universitas Muhammadiyah Malang

¹akmalmao@webmail.umm.ac.id., ²qhistindyh@webmail.umm.ac.id.,

Abstract

Pneumonia infection is a lung disease with various possible causes. The development of technology today is advancing rapidly and rapidly in various fields, one of which is in the health sector. Machine Learning or machine learning in artificial intelligence, designing and developing deeper learning models to solve any problem takes up more time and computing resources. Convolutional Neural Network (CNN) is the development of Multilayer Perceptron (MLP) which is designed to process two-dimensional data. At the convolution layer stage, the convolution process is carried out on the previous output layer. Fully Connected Layer is a layer that is used in transforming the dimensions of a data so that it can be classified linearly. The proposed deep CNN model was trained on a pneumonia chest X-ray dataset, which contains 5856 infected and uninfected chest X-ray images. This data set was preprocessed and developed based on the chest X-ray data set. It is proposed using the CNN method to classify X-ray images of pneumonia and normal chest X-ray images. CNN is a good method for classifying various kinds of images. The best results were obtained with an accuracy rate of 94%.

Keywords: Pneumonia, CNN, Images, Classification, Chest-Xray

Abstrak

Infeksi Pneumonia adalah penyakit paru-paru dengan berbagai kemungkinan penyebab. Perkembangan teknologi di masa kini semakin melaju dengan pesat dan cepat di berbagai bidang salah satunya di dalam bidang kesehatan. Machine Learning atau pembelajaran mesin dalam kecerdasan buatan, merancang dan mengembangkan model pembelajaran yang lebih mendalam untuk memecahkan berbagai permasalahan apa pun menghabiskan lebih banyak waktu dan sumber daya komputasi. Convolutional Neural Network (CNN) merupakan pengembangan Multilayer Perceptron (MLP) yang dirancang untuk memproses data dua dimensi. Pada tahap convolution layer, dilakukan proses konvolusi pada output layer sebelumnya. Fully Connected Layer adalah layer yang digunakan dalam mentransformasikan dimensi suatu data agar dapat diklasifikasikan secara linear. Model CNN mendalam yang diusulkan dilatih pada dataset rontgen dada pneumonia, yang berisi 5856 gambar rontgen dada yang terinfeksi dan tidak terinfeksi. Kumpulan data ini diproses sebelumnya dan dikembangkan berdasarkan kumpulan data rontgen dada. Diusulkan dengan metode CNN untuk mengklasifikasikan citra rontgen pneumonia dan citra rontgen dada normal. CNN merupakan metode yang baik dalam mengklasifikasikan berbagai macam citra. Diperoleh hasil terbaik dengan tingkat akurasi 94%.

Kata kunci : *Pneumonia, CNN, Citra, Klasifikasi, Chest X-Ray*

1. Pendahuluan

Infeksi Pneumonia adalah penyakit paru-paru dengan berbagai kemungkinan penyebab.

Diantaranya adalah bakteri, virus atau jamur dapat menyebabkan Infeksi pneumonia [1]. Infeksi pneumonia menyumbang lebih dari 15% kematian pada anak-anak di bawah usia lima tahun di seluruh

dunia, dan menempati peringkat ke delapan penyebab utama kematian di AS pada 2017 [2]. Ada tiga jenis yang berbeda pada infeksi pneumonia seperti: seperti pneumonia bakterial, pneumonia virus, dan pneumonia jamur. Pneumonia bakteri merupakan infeksi Pneumonia yang paling umum terutama disebabkan oleh bakteri *Streptococcus pneumoniae* [3]. Pneumonia virus adalah Infeksi Pneumonia paling berbahaya yang disebabkan oleh respiratory syncytial virus (RSV) dan influenza tipe A dan B. Pneumonia jamur disebabkan oleh jamur *coccidioides* [4]. Pneumonia paling sering terjadi di negara berkembang, dengan negara kelebihan penduduk, polusi, dan kondisi lingkungan yang tidak higienis. Diagnosis dini dapat memainkan peran penting dalam mencegah penyakit menjadi fatal. Pemeriksaan pada rontgen dada (chest x-ray) adalah metode umum dalam mendeteksi infeksi pneumonia dan menemukan area infeksi paru-paru. Pemeriksaan rontgen dada merupakan teknik pemeriksaan radiologi yang paling umum digunakan untuk mendiagnosis berbagai penyakit paru [5].

Perkembangan teknologi di masa kini semakin melaju dengan pesat dan cepat di berbagai bidang salah satunya di dalam bidang kesehatan [6]. Baru-baru ini, metode kecerdasan buatan sedang digunakan untuk memecahkan berbagai tantangan dalam proses diagnosis medis [7]. Machine Learning atau pembelajaran mesin dalam kecerdasan buatan, merancang dan mengembangkan model pembelajaran yang lebih mendalam untuk memecahkan berbagai permasalahan apa pun menghabiskan lebih banyak waktu dan sumber daya komputasi [8].

Convolutional Neural Network (CNN) merupakan pengembangan Multilayer Perceptron (MLP) yang dirancang untuk memproses data dua dimensi [9]. CNN termasuk dalam jenis Deep Neural Network karena pendalaman pada implementasi jaringan yang tinggi dan merupakan jaringan saraf multi-layer yang unggul dalam mengenali pola visual langsung dari gambar piksel. CNN bekerja seperti MLP, tapi setiap neuron CNN direpresentasikan dalam bentuk dua dimensi dengan operasi linier menggunakan operasi konvolusi, dan bobotnya tidak lagi hanya satu dimensi, tetapi bentuk empat dimensi, yaitu kumpulan kernel konvolusi [10]. CNN terdiri dari beberapa layer, terdapat 4 layer utama pada CNN diantaranya : Convolution Layer, Subsampling Layer, Fully Connected Layer, dan Fungsi Aktivasi [11].

Pada tahap convolution layer, dilakukan proses konvolusi pada output layer sebelumnya [12]. Konvolusi mengekstraksi fitur dari input pada citra. Selain itu, konvolusi mengimplementasikan sebuah fungsi pada output fungsi lain secara berulang-ulang [13]. Pada CNN, proses konvolusi mengaplikasikan sebuah kernel yang memungkinkan dari citra disemua offset [14]. Kernel melakukan pergerakan dari sudut kiri atas hingga sudut kanan bawah. Output dari proses konvolusi pada data citra adalah transformasi linier dari data input yang sesuai dengan informasi spasial data [15]. Pada data citra, subsampling layer mereduksi ukuran suatu data yang ada didalamnya. Subsampling berfungsi dalam peningkatan invariansi fitur dan posisi [16]. Max Pooling merupakan salah satu subsampling yang sering dimanfaatkan dalam pembuatan model CNN. Max pooling membagi output dari convolution layer hingga menghasilkan beberapa grid berukuran kecil dan mengambil nilai maksimum untuk menyusun matriks dari setiap grid [17]. Tujuan proses tersebut adalah tetap memastikan fitur yang dijalankan akan sama walau terjadi pergeseran pada objek citra [18].

Fully Connected Layer adalah layer yang digunakan dalam mentransformasikan dimensi suatu data agar dapat diklasifikasikan secara linear. [19] Setiap neuron pada convolution layer perlu ditransformasi menjadi data satu dimensi terlebih dahulu sebelum dapat dimasukkan ke dalam sebuah fully connected layer. Fully Connected Layer hanya dapat digunakan di akhir jaringan agar data yang dijalankan tidak kehilangan informasi spasial dan tidak reversibel [20].

Komponen utama yang keempat pada CNN adalah fungsi aktivasi. Komponen ini mentransformasikan data input menjadi dimensi yang lebih tinggi hingga memungkinkan dalam memotong hyperlane sederhana dalam klasifikasi [21]. Fungsi aktivasi termasuk fungsi non linear yang berpengaruh dalam mentransformasikan data input menjadi dimensi yang lebih tinggi. Fungsi aktivasi yang digunakan dalam penelitian ini adalah sigmoid. Sigmoid mentransformasikan range nilai input pada x menjadi nilai dengan kisaran diantara 0 dan 1 [22].


Beberapa penelitian sebelumnya yang dijadikan pendukung dalam penelitian terkait diantaranya adalah penelitian yang digagaskan oleh Thakur et.al dengan melakukan penelitian klasifikasi citra x-ray menggunakan dataset yang sama. Hasil yang didapat dari penelitian dengan menggunakan VGG16 adalah didapat hasil akurasi sebesar 90.5% dengan nilai presisi sebesar 87.7%, recall 97.7%, dan F1-Score 92.9% . Penelitian oleh Vijayakumar

Bhandi et al mengusulkan radiografi x-ray dada dibagi menjadi 2 jenis klasifikasi dan menggunakan algoritma CNN model, Inception V3, VGG19, dan ResNet50 pre-trained. Berbeda dengan Vijayakumar Bhandi, Naufal, M.F., et.al. mengusulkan 2 kelas radiografi x-ray dada dengan menggunakan algoritma K-Nearest Neighbors (KNN), Support Vector Machine (SVM), dan CNN. Mundher Mohammed Taresh et al mengusulkan 8 model berbeda dengan VGG16 dan MobileNet memperoleh akurasi tertinggi 98,28%. Abeer Badawi et al mengusulkan penggunaan 3 model pre-trained DenseNet-201, VGG16, dan VGG19 untuk mengklasifikasikan radiografi x-ray covid pada tahun 2021. Kemudian, Pebri Andhi H. P. et al juga mengusulkan 3 model berbeda dengan menggunakan model pre-trained, diantaranya : VGG19, ResNet50, dan InceptionV3 dengan mendapat hasil akurasi terbaik pada model VGG19 sebesar 94,44%. Tuan D. Pham et al membuat 4 model pre-trained : AlexNet, GoogleNet, dan SqueezeNet dan membagi radiografi x-ray dada dengan berbagai dataset publik yang ada dan mendapat rata-rata mendapat akurasi tinggi diatas 95%.

Pada penelitian ini, peneliti mengusulkan untuk klasifikasi radiografi x-ray dada menggunakan algoritma Convolutional Neural Network. Dataset yang diperoleh dari situs kaggle dengan judul dataset COVID-19 Radiography Database dengan jumlah 10015 citra yang berfokus pada 3 kategori yaitu Normal, Covid, dan Viral-Pneumonia.

2. Metode Penelitian

Proses dalam pengerjaan image Classification berawal dari pengambilan dataset dari kaggle, khususnya data citra rontgen pneumonia, yang kemudian proses preprocessing dataset guna mendapatkan data yang tersiap kan dengan baik, lalu dilanjutkan dengan mengumpulkan nilai pada setiap pixel citra bersamaan dengan resize setiap citra. Kemudian augmentasi citra. Dilanjutkan dengan klasifikasi citra. Dan diakhiri dengan evaluasi hasil.



Gambar 1. Alur Penelitian

2.1 Dataset Penelitian

Data penelitian ini adalah dataset citra yang di dapatkan pada situs kaggle. Data tersebut terdiri atas beberapa folder yaitu Training, Validation, dan Test Terdapat 5858 citra rontgen keseluruhan. 3875 citra merepresentasikan citra rontgen pneumonia dan 1341 citra merepresentasikan citra rontgen normal Dataset tersebut dibagi kedalam data uji sebanyak data training berjumlah 5,216 data citra, data tes berjumlah 624 data citra, data validasi berjumlah 16 data. Yang nantinya akan di bagi kembali menjadi. 80% data citra training, 19% data citra validation, dan 1% untuk citra test. 3.2 Data Preprocessing Langkah pertama dalam preprocessing dalam penelitian ini adalah membersihkan dataset selain citra. Dilanjutkan dengan membagi kembali dataset dikarenakan dataset validation terlalu kecil maka diperlukan pembagian ulang / split dataset. Pembagian dataset menjadi 80% data citra training, 19% data citra validation, dan 1% untuk citra test. Dilanjutkan mengambil nilai pixel pada citra, kemudian di lakukan normalisasi nilai dibagi 255 agar nilai mudah diproses pada proses selanjutnya. 3.3 Augmentasi Data Augmentasi merupakan teknik manipulasi data tanpa menghilangkanan inti atau esensi dari data. Dalam penelitian ini dilakukan rotation, width shift, height shift, zoom, horizontal flip, dan fill.

Augmentation Lis	Value
Rotation	40
Width Shift	0.2
Height Shift	0.2
Zoom	0.2
Horizontal Flip	True
Fill Mode	Nearest

Tabel 1. Data Augmentasi

2.2 CNN

model CNN, nilai dimensi citra pada input sebesar $150 * 150 * 3$. Dalam feature extraction ;ayer terdapat 3 layer yang berulang yaitu Conv2D, Batch Normalization, MaxPooling2D. Tiap layer Conv2D yang pertama dan seterusnya filter bertambah 2 kali lebih besar yaitu sebesar 16, 32, 64. Lalu dilakukan Dropout sebesar 0.5 lalu dilakukan Flatten. Dilanjutkan pada fully connected layer dilakukan Dense sebesar 128 dengan activation Relu, Dropout sebesar 0.5 dan Dense sebesar 1 dengan activation sigmoid. Gambar 2 Menunjukkan model CNN yang dirancang.

Layer (type)	Output Shape	Param
conv2d	(None, 150, 150, 16)	448
batch_normalization	(None, 150, 150, 16)	64
max_pooling2d	(None, 75, 75, 16)	0
conv2d_1	(None, 75, 75, 32)	4640
batch_normalization_1	(None, 75, 75, 32)	128
max_pooling2d_1	(None, 38, 38, 32)	0
conv2d_2	(None, 38, 38, 64)	18496
batch_normalization_2	(None, 28, 28, 128)	256
max_pooling2d	(None, 19, 19, 64)	0
dropout	(None, 19, 19, 64)	0
flatten	(None, 23104)	0
dense	(None, 128)	2957440
dropout	(None, 128)	0
dense	(None, 1)	129

Gambar 2. Model CNN 1

Pada model CNN 2 menggunakan input berdimensi $150 * 150 * 3$. Setelah memproses gambar di lapisan konvolusi pertama arsitektur VGG16, dimensi dapatkan pengurangan menjadi $75 * 75 * 64$ dan capai status pengumpulan maksimum. Max-pooling membantu dalam kompresi piksel data gambar ke dimensi yang lebih rendah. Secara bertahap berkurang menjadi $4 * 4 * 512$ oleh lapisan terakhir. Setelah reduksi, gambar diratakan. Perataan mengubah data menjadi larik 1-D dan larik terhubung ke yang terhubung sepenuhnya lapisan. Bobotnya diatur sesuai dengan bobot ImageNet yang telah dilatih sebelumnya. Di sini, pembelajaran transfer digunakan untuk memanfaatkan arsitektur yang telah dilatih sebelumnya.

Layer (type)	Output Shape	Param
Input Image	(None, 150, 150, 3)	448
Block conv1	(None, 150, 150, 64)	64
Block conv2	(None, 150, 150, 64)	0
Block1_pool	(None, 75, 75, 64)	4640
Block2 conv1	(None, 75, 75, 128)	128
Block2 conv2	(None, 37, 37, 128)	0
Block2_pool	(None, 37, 37, 128)	18496
Block3 conv1	(None, 37, 37, 256)	256
Block3 conv3	(None, 75, 75, 256)	0
Block3_pool	(None, 18, 18, 256)	0
flatten	(None, 23104)	0
dense	(None, 128)	2957440
dropout	(None, 128)	0
dense	(None, 1)	129

Gambar3. Model CNN 2

Model 3 menggunakan input berdimensi $150 * 150 * 3$. Menggunakan arsitektur model dengan pre-trained VGG16 dengan Maxpooling. Max-pooling membantu dalam kompresi piksel data gambar ke dimensi yang lebih rendah. Pada tambahan bagian Fully Connected Layer menggunakan Dropout 0.7

Layer (type)	Output Shape	Param
Input Image	(None, 150, 150, 3)	448
Block conv1	(None, 150, 150, 64)	64
Block conv2	(None, 150, 150, 64)	0
Block1_pool(MaxPooling 2D)	(None, 75, 75, 64)	4640
Block2 conv1	(None, 75, 75, 128)	128
Block2 conv2	(None, 37, 37, 128)	0
Block2_pool(MaxPooling 2D)	(None, 37, 37, 128)	18496
Block3 conv1	(None, 37, 37, 256)	256
Block3 conv3	(None, 75, 75, 256)	0

Block3_pool (MaxPooling 2D)	(None, 18, 18, 256)	0
block4_conv1 (Conv2D)	(None, 18, 18, 512)	1180160
block4_conv2 (Conv2D)	(None, 18, 18, 512)	2359808
block4_conv3 (Conv2D)	(None, 18, 18, 512)	2359808
block5_conv1 (Conv2D)(MaxPooling)	(None, 9, 9, 512)	2359808
block5_conv2 (Conv2D)	(None, 9, 9, 512)	2359808
block5_conv3 (Conv2D)	(None, 9, 9, 512)	2359808
flatten	(None, 8192)	0
Dense_9	(None, 256)	2957440
Dropout_6	(None, 256)	0
Dense_10	(None, 256)	129
Dropout_7	(None, 256)	0
Dense_11	(None, 1)	129

Gambar 4. Model CNN 3

Pada tahapan compile menggunakan optimizer Adam dengan learning rate sebesar 0.001, loss menggunakan binary crossentropy.

3. Hasil dan Pembahasan


Setelah melakukan eksperimen dengan menggunakan model di atas. Hasil yang didapatkan adalah sebagai berikut. Dari model tersebut didapatkan bahwa F1-Score Accuracy-nya cukup bagus dengan waktu training per epoch relatif cepat. Pada penelitian ini dilakukan 100 epoch untuk mendapatkan perubahan grafik yang baik.

Model	Accuracy	Precision	Recall	F1-Score
VGG16 [1]	90.5%	87.7%	98.7%	92.9%
Scenario 1	91%	88.5%	89.5%	88.5%
Scenario 2-Proposed Method	94%	93.5%	91%	93%


Tabel 2. Hasil Evaluasi

Tabel 2 adalah hasil evaluasi ketiga model yang telah dijalankan, diperoleh nilai akurasi, presisi, recall, dan juga f1-score. Hasil tabel menunjukkan bahwa nilai akurasi terbesar didapat oleh Model CNN 1 dengan nilai akurasi 94%, kemudian disusul


CNN 3 dengan 0.5akurasi 90.5%, kemudian CNN 3 dengan akurasi 93%.



Gambar 5. Grafik Akurasi Model CNN 1

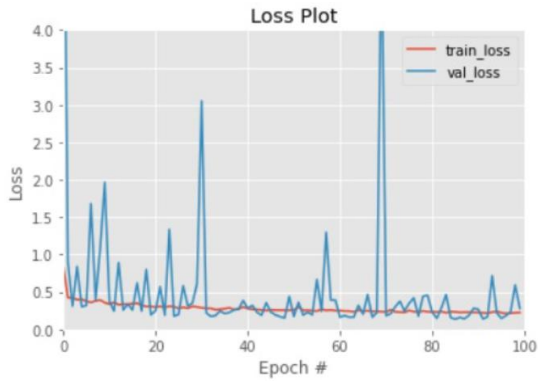


Gambar 6. Grafik Akurasi Model CNN 2



Gambar 7. Grafik Akurasi Model CNN 3


Hasil pelatihan tiap model kemudian divisualisasikan melalui grafik akurasi. Gambar 5, 6, 7 secara berturut-turut menunjukkan grafik akurasi yang didapat dengan menggunakan CNN 1, CNN 2, dan CNN 3. Sedangkan untuk Gambar 8, 9, 10 menunjukkan grafik loss untuk CNN 1, CNN 2, dan CNN 3. Nilai yang ditunjukkan pada sumbu X merupakan jumlah iterasi pelatihan selama proses menjalani pelatihan model yang berada di rentang 0 sampai 100. Nilai pada sumbu Y merupakan nilai tingkat akurasi yang didapat ketika menjalankan model yang telah dibangun.



Gambar 8. Grafik Loss Model CNN 1



Gambar 9. Grafik Loss Model CNN 2



Gambar 10. Grafik Loss Model CNN 3

4. Kesimpulan

Pengimplementasian deep learning metode CNN dengan menggunakan beberapa model diantaranya 1 CNN 1, CNN 2, dan CNN 3 dengan semua model menggunakan Fully Connected Layer dalam penelitian klasifikasi citra x-ray dengan hasil performa :

1. CNN 1 model mendapat nilai akurasi sebesar 94%. Mendapat nilai presisi sebesar 93.5%, recall 91%, dan F1-Score 93%
2. CNN 2 model mendapat hasil akurasi sebesar 90.5%. Mendapat nilai presisi

sebesar 87.7%, recall 97.7%, dan F1-Score 92.9%

3. CNN 3 dengan VGG16 mendapat hasil akurasi sebesar 96%. Mendapat nilai presisi sebesar 88.5%, recall 89.5%, dan F1-Score 88.5%

Daftar Rujukan

- [1] S. Thakur, Y. Goplani, S. Arora, R. Upadhyay, and G. Sharma, "Chest X-Ray Images Based Automated Detection of Pneumonia Using Transfer Learning and CNN," *Adv. Intell. Syst. Comput.*, vol. 1164, pp. 329–335, 2021.
- [2] R. E. Al Mamlook, S. Chen, and H. F. Bzizi, "Investigation of the performance of Machine Learning Classifiers for Pneumonia Detection in Chest X-ray Images," *IEEE Int. Conf. Electro Inf. Technol.*, vol. 2020-July, pp. 98–104, Jul. 2020.
- [3] G. Labhane, R. Pansare, S. Maheshwari, R. Tiwari, and A. Shukla, "Detection of Pediatric Pneumonia from Chest X-Ray Images using CNN and Transfer Learning," *Proc. 3rd Int. Conf. Emerg. Technol. Comput. Eng. Mach. Learn. Internet Things, ICETCE 2020*, pp. 85–92, Feb. 2020.
- [4] S. Karakanis and G. Leontidis, "Lightweight deep learning models for detecting COVID-19 from chest X-ray images," *Comput. Biol. Med.*, vol. 130, p. 104181, Mar. 2021.
- [5] M. Nath and C. Choudhury, "Automatic Detection of Pneumonia from Chest X-Rays Using Deep Learning," *Commun. Comput. Inf. Sci.*, vol. 1240 CCIS, pp. 175–182, Jul. 2020.
- [6] Y. Muhammad, M. D. Alshehri, W. M. Alenazy, T. Vinh Hoang, and R. Alturki, "Identification of Pneumonia Disease Applying an Intelligent Computational Framework Based on Deep Learning and Machine Learning Techniques," *Mob. Inf. Syst.*, vol. 2021, 2021.
- [7] H. Behzadi-khormouji et al., "Deep learning, reusable and problem-based architectures for detection of consolidation on chest X-ray images," *Comput. Methods Programs Biomed.*, vol. 185, p. 105162, Mar. 2020.
- [8] R. Yi, L. Tang, Y. Tian, J. Liu, and Z. Wu, "Identification and classification of pneumonia disease using a deep learning-based intelligent

- computational framework,” *Neural Comput. Appl.* 2021, pp. 1–14, May 2021.
- [9] M. A. Abbasa, S. U. K. Bukhari, S. K. A. Bokhari, and manal niazi, “The application of Hybrid deep learning Approach to evaluate chest ray images for the diagnosis of pneumonia in children,” *medRxiv*, p. 2020.12.03.20243550, Dec. 2020.
- [10] I. Sirazitdinov, M. Kholiavchenko, T. Mustafaev, Y. Yixuan, R. Kuleev, and B. Ibragimov, “Deep neural network ensemble for pneumonia localization from a large-scale chest x-ray database,” *Comput. Electr. Eng.*, vol. 78, pp. 388–399, Sep. 2019.
- [11] H. Ren et al., “Interpretable Pneumonia Detection by Combining Deep Learning and Explainable Models with Multisource Data,” *IEEE Access*, vol. 9, pp. 95872–95883, 2021.
- [12] V. Chouhan et al., “A Novel Transfer Learning Based Approach for Pneumonia Detection in Chest X-ray Images,” *Appl. Sci.* 2020, Vol. 10, Page 559, vol. 10, no. 2, p. 559, Jan. 2020.
- [13] A. Tilve, S. Nayak, S. Vernekar, D. Turi, P. R. Shetgaonkar, and S. Aswale, “Pneumonia Detection Using Deep Learning Approaches,” *Int. Conf. Emerg. Trends Inf. Technol. Eng. ic-ETITE 2020*, Feb. 2020.
- [14] T. Rahman et al., “Transfer Learning with Deep Convolutional Neural Network (CNN) for Pneumonia Detection Using Chest X-ray,” *Appl. Sci.* 2020, Vol. 10, Page 3233, vol. 10, no. 9, p. 3233, May 2020.
- [15] A. K. Acharya and R. Satapathy, “A deep learning based approach towards the automatic diagnosis of pneumonia from chest radio-graphs,” *Biomed. Pharmacol. J.*, vol. 13, no. 1, pp. 449–455, 2020.
- [16] C. J. Saul, D. Y. Urey, and C. D. Taktakoglu, “Early Diagnosis of Pneumonia with Deep Learning,” *Apr.* 2019.
- [17] J. P. Cohen et al., “Predicting COVID-19 Pneumonia Severity on Chest X-ray With Deep Learning,” *Cureus*, vol. 12, no. 7, Jul. 2020.
- [18] S. R. Islam, S. P. Maity, A. K. Ray, and M. Mandal, “Automatic Detection of Pneumonia on Compressed Sensing Images using Deep Learning,” *2019 IEEE Can. Conf. Electr. Comput. Eng. CCECE 2019*, May 2019.
- [19] R. Kundu, R. Das, Z. W. Geem, G.-T. Han, and R. Sarkar, “Pneumonia detection in chest X-ray images using an ensemble of deep learning models,” *PLoS One*, vol. 16, no. 9, p. e0256630, Sep. 2021.
- [20] J. C. Y. Seah et al., “Effect of a comprehensive deep-learning model on the accuracy of chest x-ray interpretation by radiologists: a retrospective, multireader multicase study,” *Lancet Digit. Heal.*, vol. 3, no. 8, pp. e496–e506, Aug. 2021.
- [21] Y. Li, Z. Zhang, C. Dai, Q. Dong, and S. Badrigilan, “Accuracy of deep learning for automated detection of pneumonia using chest X-Ray images: A systematic review and meta-analysis,” *Comput. Biol. Med.*, vol. 123, p. 103898, Aug. 2020.
- [22] T. Gabruseva, D. Poplavskiy, and A. Kalinin, “Deep Learning for Automatic Pneumonia Detection.” pp. 350–351, 2020.
- [23] N. M. Elshennawy and D. M. Ibrahim, “Deep-Pneumonia Framework Using Deep Learning Models Based on Chest X-Ray Images,” *Diagnostics* 2020, Vol. 10, Page 649, vol. 10, no. 9, p. 649, Aug. 2020.
- [24] A. U. Ibrahim, M. Ozsoz, S. Serte, F. Al-Turjman, and P. S. Yakoi, “Pneumonia Classification Using Deep Learning from Chest X-ray Images During COVID-19,” *Cogn. Comput.* 2021, vol. 1, pp. 1–13, Jan. 2021.
- [25] E. Ayan and H. M. Ünver, “Diagnosis of pneumonia from chest X-ray images using deep learning,” *2019 Sci. Meet. Electr. Biomed. Eng. Comput. Sci. EBBT 2019*, Apr. 2019.
- [26] O. Stephen, M. Sain, U. J. Maduh, and D. U. Jeong, “An Efficient Deep Learning Approach to Pneumonia Classification in Healthcare,” *J. Healthc. Eng.*, vol. 2019, 2019.
- [27] Putra, I.E. (2016). Klasifikasi Citra Menggunakan Convolutional Neural Network (CNN) pada Caltech 101. *Jurnal Teknik ITS*, 5, 191064.
- [28] Kundu R, Das R, Geem ZW, Han G-T, Sarkar R (2021) Pneumonia detection in chest X-ray images using an ensemble of deep learning models. *PLoS ONE* 16(9): e0256630. <https://doi.org/10.1371/journal.pone.0256630>